www.qconferences.com www.qconbeijing.com www.qconshanghai.com



伦敦 | 北京 | 东京 | 纽约 | 圣保罗 | 上海 | 旧金山

London · Beijing · Tokyo · New York · Sao Paulo · Shanghai · San Francisco

QCon全球软件开发大会

International Software Development Conference

nfo Q



QCon

www.qconferences.com



微信后台存储架构

许家滔

sunnyxu@tencent.com

微信产品部一基础平台组



大纲

- ◎ 微信通用存储系统(Quorumkv)
 - 前言(需求背景)
 - ◎ 系统概况

 - ◎ 真实系统



前言一微信分布

- ◎ 上海 天津 深圳 香港 加拿大 ...
- ◎ 同城多园区分布



系统概况

数据存储基础设施

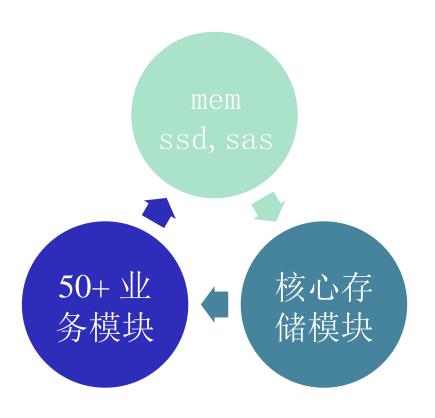
分布式强一致

同城园区级容灾

支持类SQL查询



系统概况





系统架构 一 背景

A.分布式问题收敛

后台逻辑模块专注逻辑, 快速开发

可能读取到过时的数据是个痛点

需要看到一致的数据



系统架构 一 背景

B.内部定义

数据拥有两个以上的副本

如果成功提交了变更,那么不会再返回旧数据



系统架构 一推演

1.增加一个数据



系统架构 一推演

2.序列号发生器,偏序

约束:只能有一个client操作

client有解决冲突的能力

问题转移: client如何分布?



系统架构

- 3.修改集群中一个指定key的value
 - 1)覆盖它
 - 2) 根据value的内容做修改

if value = 1 then value = 2



系统架构

1.通用解法:

1) paxos算法

工程难度

一切可控



系统架构 一 分布算法设计

2) Quorum算法 (2011)

在单个key上面运算

真实系统约束

类paxos方案,简化



系统架构 一 分布算法设计

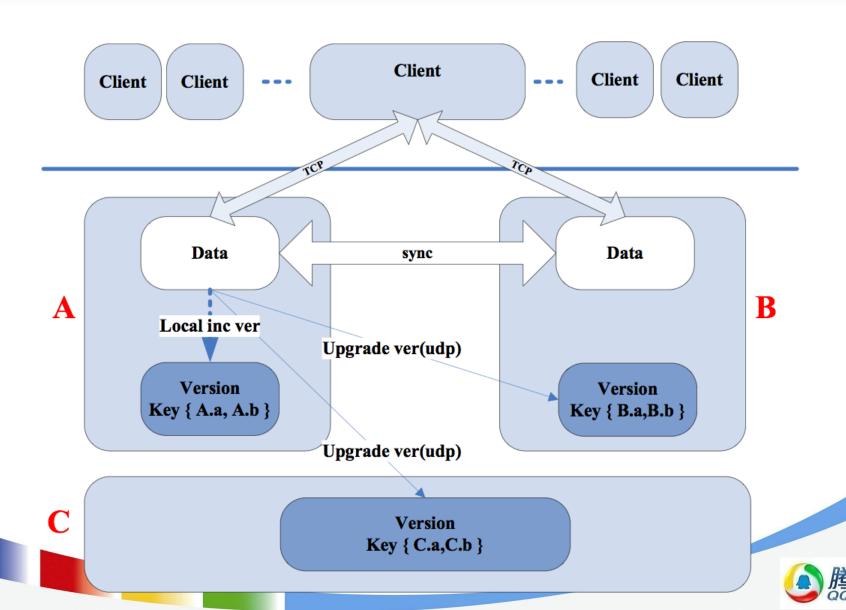
为每次变更选举(by key)

算法过程

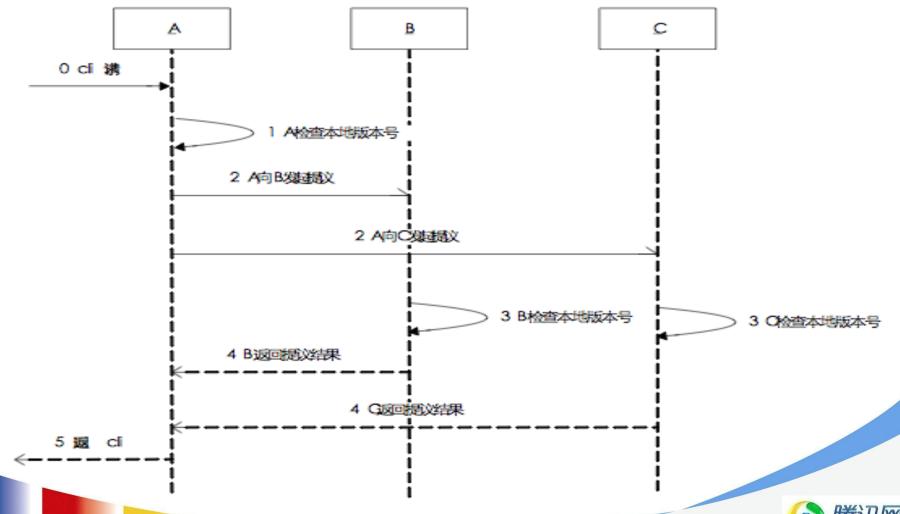
提议/变更/同步/广播



系统架构



系统架构 一 写流程





系统架构 — Replication & Sharding

权衡点

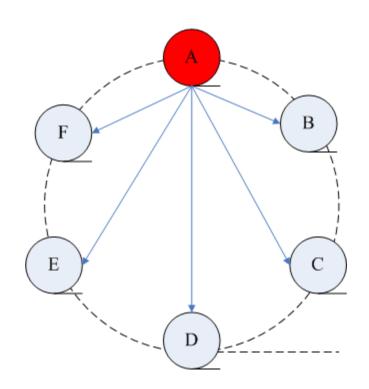
自治,负载均衡,扩散控制 replication -> relation

容灾低消

同城(上海)多数派存活 三园区(独立供电,独立。。)

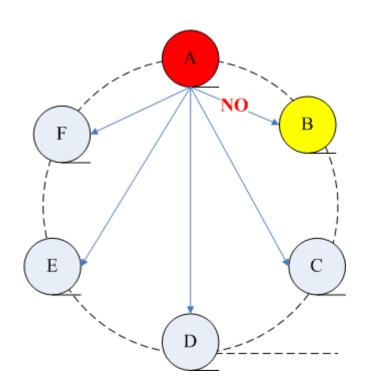


系统架构 — Replication





系统架构 — Replication





系统架构 — Sharding

- 一组kv6为一个单位
- 1. 人工分段 局部扩容,影响收敛
- 2. 均匀分布 指定分段 hash32(string) 翻倍扩容
- 3. 一致性哈希 具体实现?

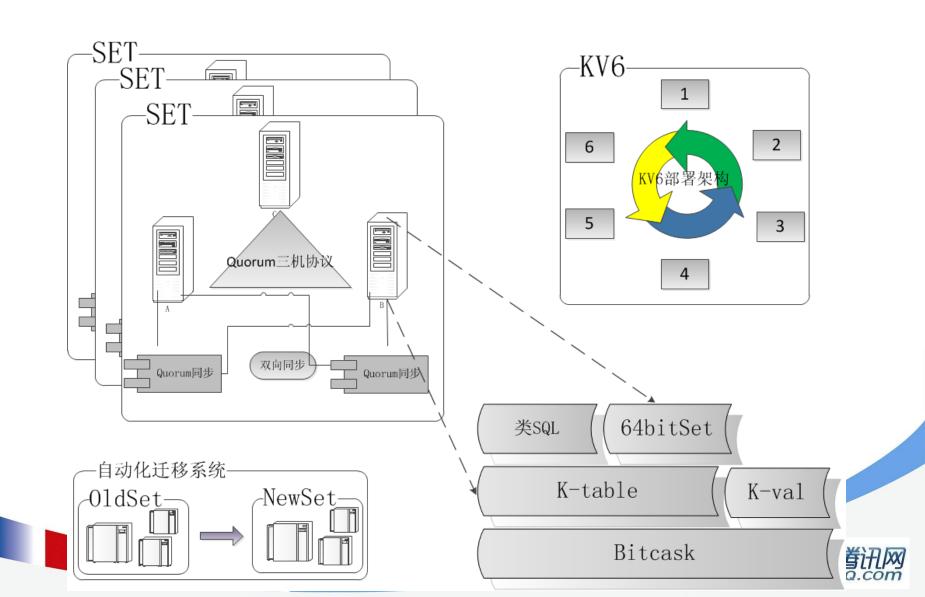


系统架构 一 概览

- 1. 业务侧快速开发 存储需要提供<mark>强一致性</mark> 丰富的数据模型支持(结构化/类SQL/KV) 条件读,条件写
- 2. 业务增长迅速,系统要能够方便地横向扩容
- 3. 设备故障/短时节点失效成为常态,容灾自动化,主备可写无需人工介入
- 4. 小数据



系统架构 一 概览



系统架构 - 存储模型

纯内存

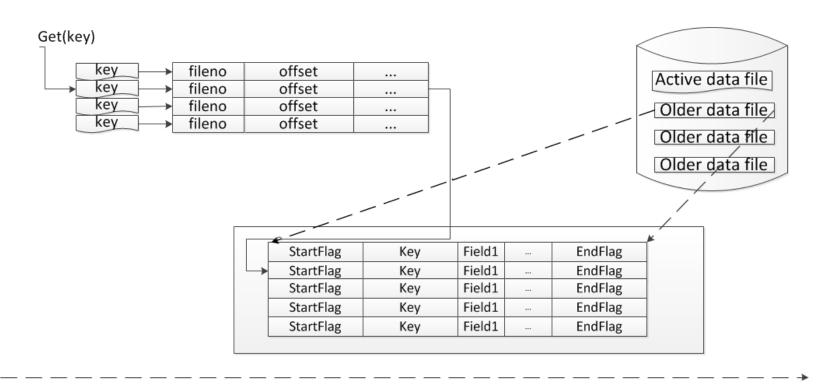
Bitcask

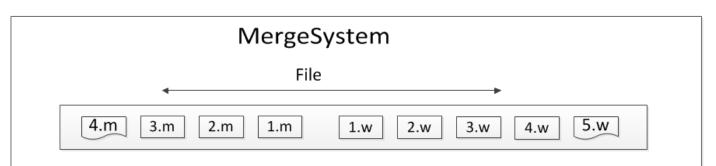
小表系统

LSM-tree



系统架构 — bitcask







系统架构 一小表系统

解决写放大问题

数据按变更聚集存储 Affected 1

分裂与合并



系统架构 — 数据流动

- ◎ 自动化迁移
- ◎ 节点同时做代理
- 合并磁盘io



真实系统 一 同步流量

- ❷ 同步流量
 - 数据 vs 操作
 - ◎ 幂等
 - 保底策略



真实系统一通信包量

- ◎ 动态合并
 - 100k qps
 - \circ 200% 10%
- ❷ 权衡与估算
- ❷ 设计要点



真实系统一吞吐量

- ◎ 异步化
 - 复杂度
 - libco



真实系统一自动修复系统

- ◎ 不要让错误累积
- 全量扫描



其他

bitcask的一些变化

内存限制

全内存





Q & A sunnyxu@tencent.com

Brought by InfoQ



特别感谢合作伙伴

















































特别感谢媒体伙伴(部分)



















