

微信复杂网络与应用

Randyling(凌国惠) 2016/04

このり2016.10.20~22上海・宝华万豪酒店

全球软件开发大会2016

[上海站]



购票热线: 010-64738142

会务咨询: qcon@cn.infoq.com

赞助咨询: sponsor@cn.infoq.com

议题提交: speakers@cn.infoq.com

在线咨询(QQ): 1173834688

团・购・享・受・更・多・优・惠

优惠(截至06月21日) 现在报名,立省2040元/张

Question

对腾讯来说,什么数据最珍贵?

一来自业务的需求

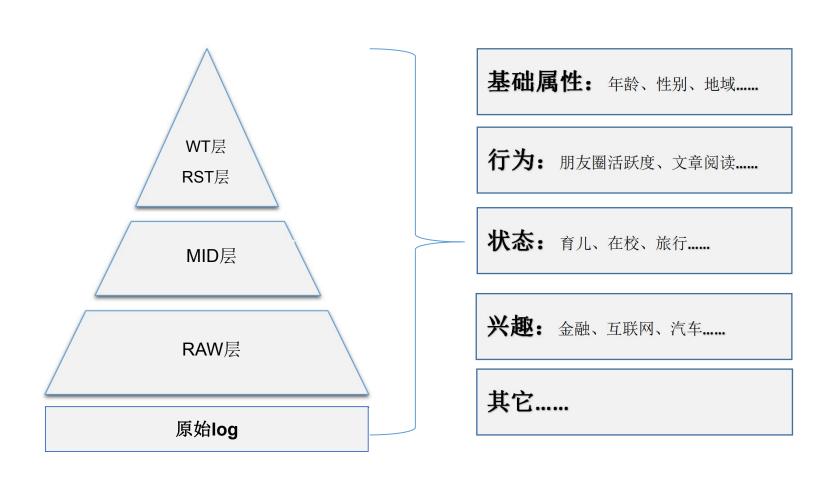
• 喜欢听周董歌曲的用户

• 有送儿童节礼物需要的用户

• 高端, 守信用的用户



挖掘过程:数据体系&用户画像

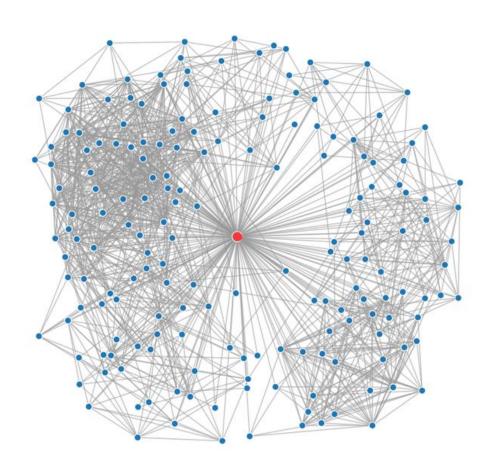


量的问题

纳尼? 才一百万用户? 我要二十倍!

分析共同点: 社交性质

微信一度好友



微信社交网络(局部图)



社团识别算法简介

算法名称	时间复杂度	实现原理
GN	$O(m^2n)$	基于边介数进行分割
LPA	O(m)	基于邻居信息进行迭代决策
CNM	O(mdlogn)	基于模块度增益进行的贪心算法
K-派系	$O(dn3^{d/3})$	基于最大团的邻接矩阵

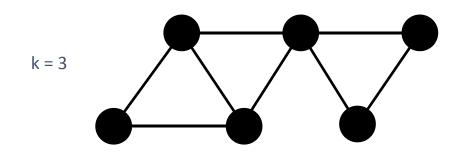
K-派系算法

相邻的 k-cliques

▶ 两个 k-cliques 有共同的 k-1 节点

k-clique 社区

▶ k-cliques 的集合: 集合中的 clique 可以通过一系列相邻的 k-clique 相互 到达



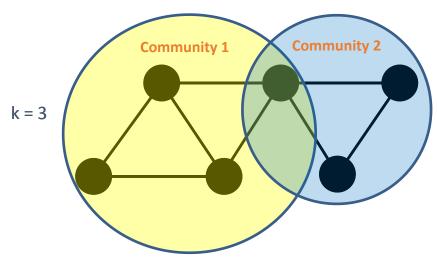
℃K-派系算法

相邻的 k-cliques

➤ 两个 k-cliques 有共同的 k-1 节点

k-clique 社区

▶ k-cliques 的集合: 集合中的 clique 可以通过一系列相邻的 k-clique 相互 到达



CNM算法(Clauset、Newman、Moore)

模块度 Q 的定义:

给定一个实际网络,假设找到一种社团划分,那么所有社团内部边数的总和为:

$$Q_{real} = \frac{1}{2} \sum_{ij} a_{ij} \delta(C_i, C_j)$$

其中 $A = (a_{ij})$ 为实际网络的邻接矩阵

 C_i 和 C_j 表示节点i 和j所属的社团; 如果i 和 j 属于同一社团则 δ 为 1; 否则 δ 取值为 0 引入一个相同规模的零模型,和 A 有相同的度序列,其他随机。用相同的社团划分有:

$$Q_{null} = \frac{1}{2} \sum_{ij} p_{ij} \delta(C_i, C_j)$$

其中 p_{ij} 是零模型网络中节点i和节点j之间连边数的期望值.

网络的一种社团划分的模块度定义为:

$$Q = \frac{Q_{real} - Q_{null}}{M} = \frac{1}{2M} \sum_{ij} (a_{ij} - p_{ij}) \delta(C_i, C_j)$$

其中M为网络的边数, $p_{ij} = \frac{k_i k_j}{2M}$, $k_i \pi k_j$ 分别为节点i 和j的度

CNM算法(Clauset、Newman、Moore)

2. cnm 算法初始时每个节点都表示一个社团,初始化增量矩阵 ΔQ 和辅助向量 a:

$$a_i = rac{k_i}{2m}$$
; $\Delta Q_{ij} = \left\{ egin{array}{ll} rac{1}{2m} - rac{k_i k_j}{(2m)^2} & \ if \ i,j \ are \ connected \ 0 & \ otherwrise \end{array}
ight.$

3. 选取最大的 ΔQ_{ij} , 执行社团 $i \to j$ 的合并,合并后模块度为: $Q = Q + \Delta Q_{ij}$; 同时更新 ΔQ 和 \boldsymbol{a} :

$$\Delta Q'_{jk} = \begin{cases} \Delta Q_{ik} + \Delta Q_{jk} & k \text{ is connected to both } i \text{ and } j \\ \Delta Q_{ik} - 2a_j a_k & k \text{ is connected to } i \text{ but not } j \\ \Delta Q_{jk} - 2a_i a_k & k \text{ is connected to } j \text{ but not } i \end{cases}$$

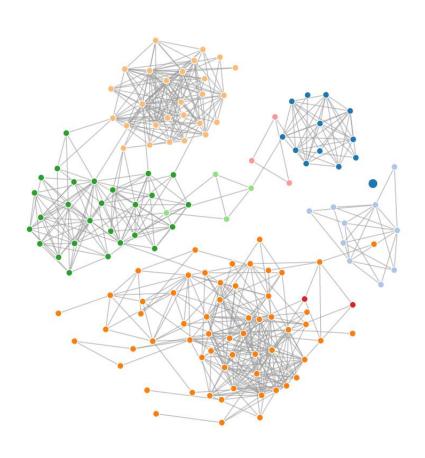
$$a'_j = a_j + a_i \quad ; \quad a_i = 0$$

4. 重复 3 直至 Q 出现首次下降, ΔQ 中所有元素都为负值,记录 Q_{max} ,此时社团合并的状态 便为 CNM 算法的社团划分结果;

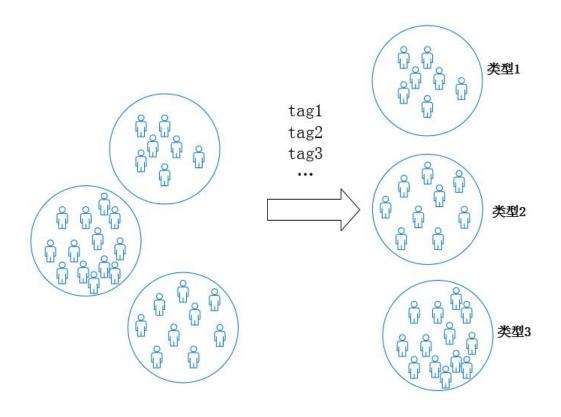
社团识别算法优化

- 算法差异
 - K派系精准,复杂度高
 - CNM效果差些,复杂度低些
- 存在问题
 - 不是同一个圈被拉进去
 - 该合并的没有被合并
- 深度优化
 - 综合运用各种算法
 - 叠加关系链之外的数据
 - 特定条件下合并

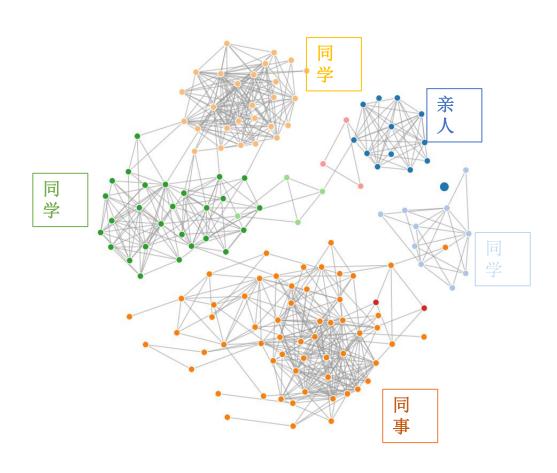








社团分类



计算难点

- 规模大
 - 点: 6.97亿+
 - 边: 千亿+
- 复杂度高



**计算框架——微信资源调度系统

• 微信后台强大 的服务器集群

• 空闲时跑挖掘计算

白天是你的, 晚上是我的

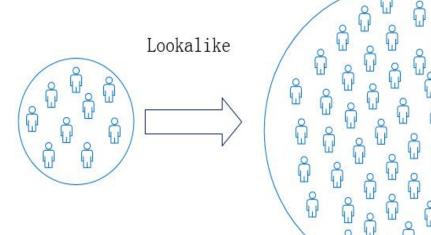
Shared cluster Data Service



€ 复杂网络应用——

• 10多倍扩散 效果依然很好

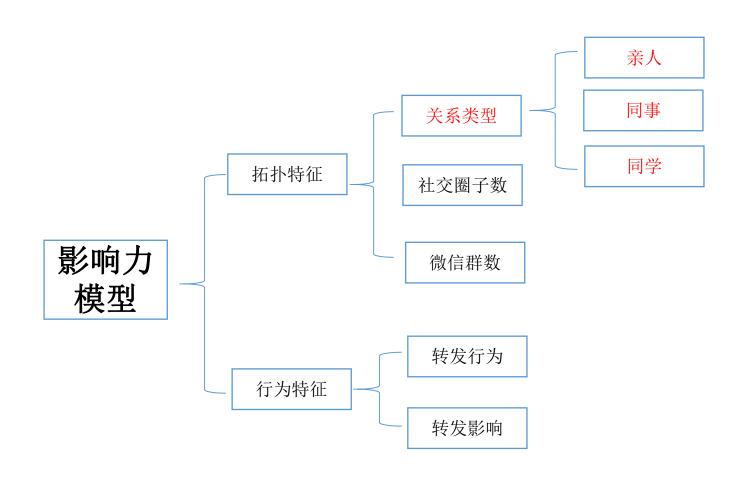
• 任意标签社交 Lookalike



• 动态投放&闭环处理



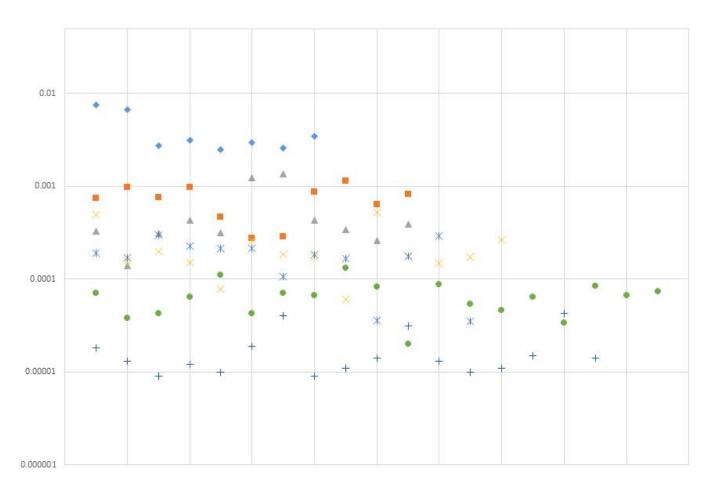
€ 复杂网络应用——社交模型





❤️复杂网络应用——People Rank

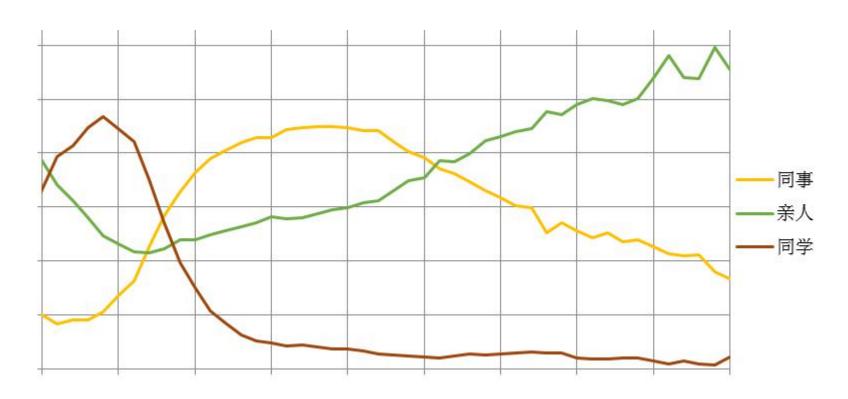
• 网络+业务 → 用户分层





€ 复杂网络应用——分析

• 微信人生——各关系类型随年龄变化



20复杂网络应用——其它

• 征信、游戏、搜索、推荐......

深入方向

• 社会层次关系

• 全局计算

• 更多业务应用





randy 🧘

广东 深圳



扫一扫上面的二维码图案, 加我微信